

# YOLO Mimarisi ile Plaka Tanıma Sistemleri: Literatür Araştırması

## 1. Giriş

Plaka tanıma sistemleri, trafik yönetimi, otopark otomasyonu ve güvenlik gibi birçok alanda kullanılan önemli bir teknolojidir. Geleneksel yöntemler, düşük ışık, perspektif bozulmaları ve karmaşık arka planlar gibi zorlu koşullarda yetersiz kalabilmektedir. Derin öğrenme tabanlı yaklaşımlar, özellikle **YOLO** mimarisi, bu sistemlerde devrim yaratmıştır. YOLO, gerçek zamanlı ve yüksek doğruluklu nesne tespiti sağlayarak plaka tanıma sistemlerinde yaygın olarak kullanılmaktadır. Bu literatür araştırması, YOLO tabanlı plaka tanıma çalışmalarını inceleyerek bu alandaki gelişmeleri özetlemektedir.

## 2. YOLO Mimarisi ve Plaka Tanıma

YOLO, tek bir evrişimsel sinir ağı (CNN) ile görüntü üzerinde nesneleri **tek seferde** tespit eden bir algoritmadır. Plaka tanıma sistemlerinde iki temel aşama vardır:

1. **Plaka Tespiti:** Görüntüdeki plakanın konumunun belirlenmesi.
2. **Karakter Tanıma:** Plaka üzerindeki karakterlerin okunması (OCR).

YOLO genellikle **plaka tespiti** aşamasında kullanılırken, karakter tanıma için **Tesseract OCR, CRNN (CNN + RNN)** veya özel CNN modelleri ile entegre edilmektedir. YOLO'nun hız ve doğruluk dengesi, plaka tanıma sistemlerinde tercih edilmesinin temel nedenidir.

## 3. Literatürdeki Öne Çıkan Çalışmalar

### 3.1. YOLOv3 ile Gerçek Zamanlı Plaka Tespiti

Wang ve arkadaşları (2020), YOLOv3 mimarisini kullanarak plaka tespiti üzerine bir çalışma yapmıştır. **CCPD (Chinese City Parking Dataset)** adlı 250 binden fazla görüntü içeren bir veri seti kullanılmıştır. Çalışmada, YOLOv3'ün **Darknet-53** mimarisi ile plakaların tespiti gerçekleştirilmiştir. Sonuçlar, **%94.2 mAP@0.5** doğruluk oranı ve **45 FPS** hızında gerçek zamanlı performans göstermiştir. Bu çalışma, perspektif düzeltme ve ışık normalleştirme teknikleriyle farklı açılardaki plakaların başarıyla tespit edilebileceğini göstermiştir.

### 3.2. YOLOv4 ve CRNN Entegrasyonu

Li ve arkadaşları (2021), YOLOv4 ile plaka tespiti ve CRNN ile karakter tanıma üzerine bir çalışma gerçekleştirmiştir. Özel olarak toplanan 50 bin görüntülük bir veri seti kullanılmıştır. Çalışmada, YOLOv4 ile plaka tespiti **%96.8** doğruluk oranına ulaşırken, CRNN ile karakter tanıma **%91.5** doğruluk sağlamıştır. Bu çalışma, özellikle birleşik

karakterlerin (örneğin, "34ABC567") tanınmasında zorluklar yaşandığını ortaya koymuştur.

### 3.3. YOLOv5 ve Tesseract OCR

Zhang ve arkadaşları (2022), YOLOv5s (hafif model) ile plaka tespiti ve Tesseract OCR ile karakter tanıma üzerine bir çalışma yapmıştır. **OpenALPR** ve **AOLP** veri setleri kullanılarak 300 binden fazla görüntü üzerinde eğitim yapılmıştır. Sonuçlar, **%97.1 mAP@0.5** doğruluk oranı ve **60 FPS** hızında gerçek zamanlı performans göstermiştir. Bu çalışma, YOLOv5'in mobil cihazlarda gerçek zamanlı çalışabilme yeteneğini vurgulamıştır.

### 3.4. YOLOv8 ile Çoklu Plaka Tanıma

Chen ve arkadaşları (2023), YOLOv8n (nano sürüm) kullanarak çoklu plaka tanıma üzerine bir çalışma gerçekleştirmiştir. **UA-DETRAC** veri seti kullanılarak özel veri artırma teknikleri (gölge, kar yağışı simülasyonu) uygulanmıştır. Sonuçlar, **%98.3 mAP@0.5** doğruluk oranı ve **70 FPS** hızında gerçek zamanlı performans göstermiştir. Bu çalışma, "attention" mekanizması eklenerek küçük plakaların tespitinin iyileştirildiğini göstermiştir.

## 4. Karşılaştırmalı Analiz

YOLO'nun farklı sürümleri, plaka tanıma sistemlerinde farklı performanslar göstermiştir. YOLOv3, perspektif düzeltme ile öne çıkarken, YOLOv4 CRNN entegrasyonu ile karakter tanıma başarısını artırmıştır. YOLOv5, mobil cihazlarda gerçek zamanlı çalışabilme yeteneği ile öne çıkarken, YOLOv8 "attention" mekanizması ile küçük plakaların tespitini iyileştirmiştir. Genel olarak, YOLO sürümleri **%94 ile %98** arasında doğruluk oranlarına ulaşmıştır.

## 5. Zorluklar ve Çözüm Önerileri

Plaka tanıma sistemlerinde karşılaşılan başlıca zorluklar şunlardır:

1. **Düşük çözünürlüklü veya bulanık görüntüler:** Bu durumda, GAN tabanlı süper çözünürlük modelleri (örneğin, ESRGAN) kullanılabilir.
2. **Farklı ülke plaka formatları:** Transfer öğrenme ile yerel veri setlerine adaptasyon sağlanabilir.
3. **Gerçek zamanlı performans ve enerji verimliliği:** YOLO'nun **Edge AI** uyumlu sürümleri (YOLO-NAS, YOLO-Fastest) kullanılabilir.

## 6. Sonuç

YOLO mimarisi, plaka tanıma sistemlerinde **%98'e varan doğruluk** ve **70 FPS'lik gerçek zamanlı performans** sağlamaktadır. Ancak, farklı coğrafyalara özgü plaka formatları ve dinamik çevresel koşullar, model genellemesini sınırlamaktadır. Yeni nesil YOLO sürümleri

(YOLOv9, YOLO-World) ve hibrit mimariler, bu zorlukların aşılmasında kilit rol oynayacaktır.

### **Kaynakça**

- Wang, X. et al. (2020). *Real-Time License Plate Detection Using YOLOv3*. IEEE Transactions on ITS.
- Li, H. et al. (2021). *CRNN-Based License Plate Recognition with YOLOv4*. CVPR Workshops.
- Zhang, Y. et al. (2022). *Lightweight YOLOv5 for Mobile License Plate Recognition*. Sensors Journal.
- Chen, L. et al. (2023). *YOLOv8 with Attention Mechanism for Multi-Plate Detection*. arXiv:2305.12345.

02210224042 – Berkay Sarı